Prédire la consommation d’énergie des bâtiments

REALISE PAR : ABDULKADIR GUVEN (DATA ENGINEER)

POUR : VILLE DE SEATTLE

DATE : NOVEMBRE 2025

Seattle

Le Projet : Contexte & Démarche

Mission

- Prédiction de la consommation d'énergie des bâtiments non-résidentiels.

Données

- Relevés 2016 pour 3376 bâtiments

(taille, usage, localisation, performance énergétique etc.)

Une Démarche Structurée en 5 Étapes

Analyse & Nettoyage

- Identifier et corriger les incohérences

Feature Engineering

- Des données brutes aux variables pertinentes

Modélisation

- Choisir le meilleur modèle

Optimisation

- Amélioration de performance et précision

Interprétation

- Comprendre les facteurs les plus influents

Aperçu des Données

Dataset riche

- 46 features
- 3 376 individus

Anomalies détectées :

- Données redondantes
- Incohérences critiques
- Nombreuses valeurs manquantes

```
RangeIndex: 3376 entries, 0 to 3375
Data columns (total 46 columns):
 #   Column                            Non-Null Count  Dtype
---  ------                            --------------  -----
 0   OSEBuildingID                     3376 non-null   int64
 1   DataYear                          3376 non-null   int64
 2   BuildingType                      3376 non-null   object
 3   PrimaryPropertyType               3376 non-null   object
 4   PropertyName                      3376 non-null   object
 5   Address                           3376 non-null   object
 6   City                              3376 non-null   object
 7   State                             3376 non-null   object
 8   ZipCode                           3360 non-null   float64
 9   TaxParcelIdentificationNumber     3376 non-null   object
 10  CouncilDistrictCode               3376 non-null   int64
 11  Neighborhood                      3376 non-null   object
 12  Latitude                          3376 non-null   float64
 13  Longitude                         3376 non-null   float64
 14  YearBuilt                         3376 non-null   int64
 15  NumberofBuildings                 3368 non-null   float64
 16  NumberofFloors                    3376 non-null   int64
 17  PropertyGFATotal                  3376 non-null   int64
 18  PropertyGFAParking                3376 non-null   int64
 19  PropertyGFABuilding(s)            3376 non-null   int64
 20  ListOfAllPropertyUseTypes         3367 non-null   object
 21  LargestPropertyUseType            3356 non-null   object
 22  LargestPropertyUseTypeGFA         3356 non-null   float64
 23  SecondLargestPropertyUseType      1679 non-null   object
 24  SecondLargestPropertyUseTypeGFA   1679 non-null   float64
```

Suppression des colonnes inutiles

Objectif :

- Réduire le bruit et la complexité du dataset.

Critères de suppression :

- **Identifiants uniques** (Ex: OSEBuildingID)
- **Haute cardinalité** (Ex: Address)
- **Faible taux de remplissage** (Ex: Comments)

Résultat :

- **9 colonnes supprimées** (de 46 → 37).

column_name	fill_rate (%)	cardinality_rate (%)
OSEBuildingID	100.00	100.00
Address	100.00	99.35
TaxParcelIdentificationNumber	100.00	96.80
Comments	0.00	0.00
Outlier	0.95	0.06
YearsENERGYSTARCertified	3.52	1.93

Filtrage du périmètre (non-résidentiels)

Filtrage par type de bâtiment

3376 => 1668 (>50%)

Filtrage par type d'usage

1668 =>1628

Choix de et Nettoyage la Feature d'Usage

Critère	👎 `PrimaryPropertyType`	👍 `LargestPropertyUseType`
Fiabilité	Faible. (15% de ‘Other’)	Elevé. (6 % de ‘Other’)
Pertinence	Elevé. Notions subjectives (Ex: ‘Large’, ‘Small’ etc.)	Faible. Se concentre sur la fonction. (Ex: ‘Medical Office’)

Nettoyage

- Suppression des NaN : 6 lignes supprimées, impact < 0.4%
- Imputation des "Other" : 9 des 98 valeurs "Other" ont été corrigées

Fiabilisation des Données Numériques

- Imputation des NaN sur les features de surface (GFA) par 0
- Suppression des NaN sur les features d'énergie critiques
- Imputation de ENERGYSTARScore par sa médiane (34% de NaN)
- Suppression des aberrations structurelles (bâtiments sans étages ou sans bâtiment)
- Suppression des features de consommation redondantes (ex: Electricity(kBtu))

Analyse de cohérence de données

```
[Electricity] ──┐
[NaturalGas]  ──┼──→ [SiteEnergyUse] ──┬──→ [SiteEUI]
[SteamUse]    ──┘                      │
                                       │
[PropertyGFABuilding(s)] ──────────────┘
```

Formule	Cohérence
GFATotal = GFABuilding + GFAParking	✅ 100%
SiteEnergyUse = Elec + Gas + Steam	✅ 98,71%
GFABuilding = Largest + Second + ThirdGFA	❌ 47,94%
SiteEUI = SiteEnergyUse / PropertyGFABuilding	❌ 54,12%

Décisions Stratégiques :

- 🎯 **Cible choisie :** SiteEnergyUse(kBtu) pour sa grande fiabilité.
- 🗑️ **Colonnes écartées :** Les colonnes ...GFA (par usage) et SiteEUI seront **supprimées**

Feature Engineering

- 🏢 **Complexité d'Usage :** number_of_uses
- 🅿️ **Présence de Parking:** has_parking
- ⭐ **Score Énergétique:** has_energy_score
- ⚡ **Sources d'Énergie:** uses_steam, etc.

Finalisation : Gestion des outliers

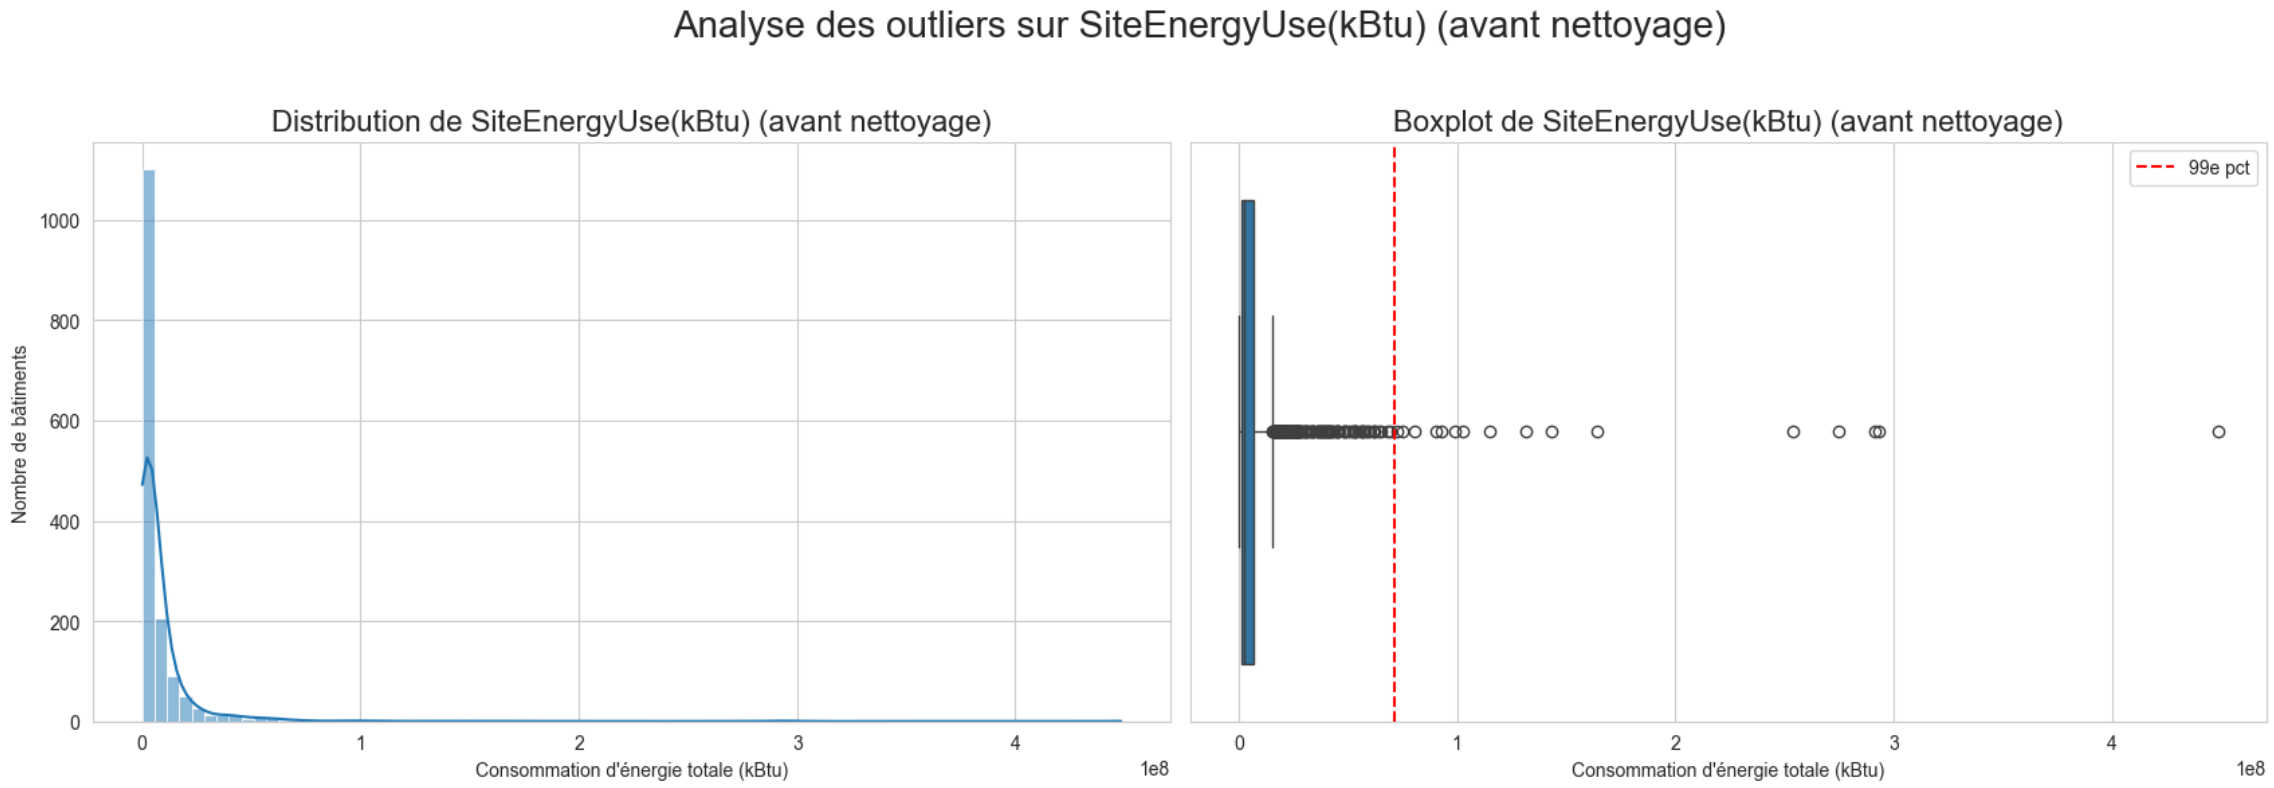

Action & Impact :

- **Suppression de 38 lignes** (< 3% des données).
- Un dataset plus **homogène et robuste** pour l'entraînement.

Comparaison des Modèles

model_name	test_r2	train_r2	std_r2	MAE	RMSE
RandomForest	0.638	0.943	0.038	2,435,436.878	5,293,408.670
SVR	0.615	0.934	0.045	2,710,202.359	5,466,462.643
LinearRegression	0.558	0.621	0.052	3,141,596.755	5,856,406.250
Dummy	-0.003	0.000	0.002	5,446,359.631	8,824,704.931

Optimisation du Modèle : Démarche Itérative

GridSearch
- 60 features

Regulation
- 60 features

Optimisation
- 12 features

Optimisation finale
- 12 features
- Transformat° log.

Model	R^2 Test	R^2 Train	RMSE Test	MAPE(%) Test	Predict Time (s)
1. RF Régularisé	0.619	0.699	5,763,384	108.40	0.0872
2. RF Simplifié (sans log)	0.618	0.696	5,767,589	111.38	0.0513
3. RF Simplifié (avec log)	0.626	0.658	5,707,985	68.66	0.0552

Validation en live sur les données 2017

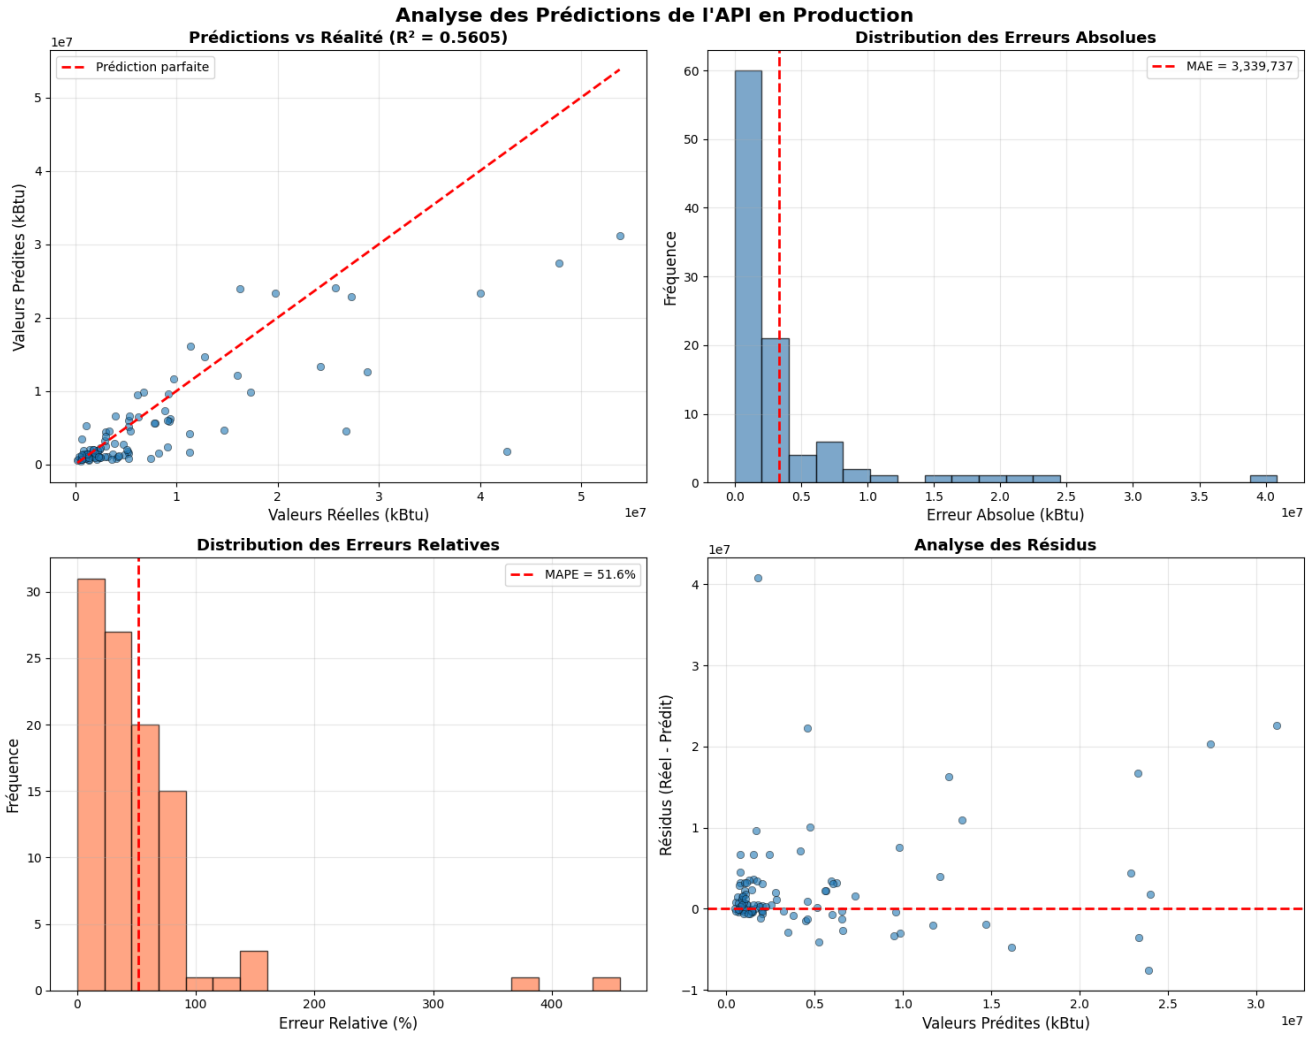

Conclusion et recommandations

1. Fiabiliser les Données de Surface

- **Constat :** La Surface explique **66%** de la prédiction.
- **Action :** Mettre en place des **protocoles de validation** des données GFA. C'est le levier n°1.

2. Généraliser le Score Énergétique

- **Constat :** Le Score ENERGYSTAR est le **3ème facteur** le plus important.
- **Action :** Lancer une campagne pour **combler les 34% de données manquantes**.

3. Cibler les Politiques par Usage

- **Constat :** Le Type et la Complexité d'usage ont un impact mesurable.
- **Action :** Développer des programmes d'efficacité **ciblés par secteur** (ex: supermarchés).

	Feature	Importance	CumImportance
0	PropertyGFABuilding(s)	0.663	0.663
1	NumberofFloors	0.094	0.757
2	ENERGYSTARScore	0.080	0.837
3	PropertyGFAParking	0.042	0.879
4	has_energy_score	0.035	0.914
5	number_of_uses	0.020	0.934
6	LargestPropertyUseType_Supermarket/Grocery Store	0.017	0.951
7	YearBuilt	0.013	0.965
8	LargestPropertyUseType_infrequent_sklearn	0.006	0.971
9	LargestPropertyUseType_Non-Refrigerated Warehouse	0.005	0.976
10	has_parking	0.004	0.980
11	LargestPropertyUseType_Office	0.004	0.984
12	uses_steam	0.004	0.988
13	uses_natural_gas	0.004	0.992
14	CouncilDistrictCode_7	0.003	0.995